

Airflow жив и здоров: разбор претензий и альтернатив



Игорь Мосягин
shrimpsizemoose AB



кто
здесь

1



Пишу на питоне с ~2009 года (с версии 2.2)

Работал бэкендером, в науке, дата сайнтистом, дата инженером, ML инженером, Analytics инженером, и т.п.

Писал код в продакшн ещё и на C/C++/Fortran/Golang

Хакатоню, опенсоршу помаленьку

Междисциплинарный художник в стиле Science Art

Преподаю. Давно, много. Очень люблю Airflow

Если вы не ходили в Питере в "Федя, дичь" -- сходите!!!




кто вы? С какой вашей частью я
хочу поговорить?

Я хочу обратиться к вашей бэкендер-субличности

У меня большой и разный опыт: у вас, наверное, тоже

Давайте поговорим как бэкенд-разработчики

А разговоры на DS/MLE/DE уровне оставим для кулуар



а кто такие оркестраторы?

Мы же все знаем что такое крон?


Расписание по крону = “что показывают часы” 

```
10 12 17 5 * do-talk
```

ежегодно 17 мая в 12:10 выполняется do-talk

```
*/7 8-22 * * * /usr/bin/think-about-spqr.sh
```

запуск скрипта раз в семь минут с 8 утра до 10 вечера



а кто такие оркестраторы?

Мы же все знаем что такое крон?

Расписание по крону = “что показывают часы” 

Можешь задать расписание? → юзай крон

Не можешь? → прячь логику в скрипт

Что мы делаем когда хотим писать на питоне?

добавляем APScheduler *[как произносим?]*

А если хотим цепочки задач/воркеры?

добавляем celery/dramatiq/rq/taskiq

как и
зачем
это всё

2



Что нужно автоматизировать в Data-задачах?

- заливать данные из одной базы в другую
- проверять что в данных всё ок (schema-on-read)
- считать метрики и обновлять дашборд
- оценивать KPI и обновлять гуглтабличку
- обновлять веса модели на новых данных
- делать API запросы куда-то на основании ответов из другого API (вплоть до LFT)
- и так далее (предложите ваш вариант)


*в таких задачах вам не поможет крон. УВЫ
ДАВАЙТЕ ПОДУМАЕМ, Почему?*

Из каких частей состоит подобная система?


- нам нужны часы -- scheduler
- мы хотим observability
- нужен фреймворк для описания логики
- желательно, что-то для тестов
- интерфейс для юзера


ключевые компоненты оркестратора это они и есть!


webserver
scheduler
executor



Apache Airflow







Статусы тасок
тоже надо
как-то учитывать

а ещё их надо
как-то
соединять...

Component
 Task state
 Task state only for sensor
 State transition

DAG

фундаментальное понятие CS
Direct Acyclic Graph



Расшифровываем буквы

Direct:


- Есть понимание направления в графе (для $\forall$ ноды)

Acyclic:

- Нет петель

Graph:

- Всё переплетено
- У этого “Всего” есть структура
- У каждой ноды можно найти родителя/потомка



Airflow с точки зрения Airflow

Apache Airflow - A platform to programmatically author, schedule, and monitor workflows

<https://airflow.apache.org/>

Python 🤘, комьюнити, используется всеми, почти стандарт (мало конкурирующих решений с похожими фичами)

Важно: Airflow в целом наплевать, что вы в нём запускаете

Начиная с 2020 многие пытаются "убить" Airflow
один из пожалуй популярных конкурентов это dagster

Dagster с точки зрения Dagster

Dagster - An orchestration platform for the development, production, and observation of data assets.

<https://dagster.io/>

Dagster тоже на Python 🙌 с быстро растущим комьюнити, его очень любят те, кто занимается analytics engineering

Важно: Dagster во главу ставит не задачи, а **данные** и фокусируется на преобразовании ассетов

mini
Demo

4 Airtrow



историческая справка на 30 секунд

Начал Maxime Beauchemin в Airbnb в далёком 2014
раньше было больше бардака, сейчас меньше
недавно перевалили за 30к коммитов (и 40k ★)

Большие изменения

1.10->2->2.3->2.5->2.8->2.10->3.0

(Apache Incubator 2015-2019, под Astronomer с 2018)

[Страница описания релизов](#)



компоненты Airflow

Webserver – GUI смотреть, даги дёргать, метрики

Scheduler – запускает пайплайны, смотрит на часы

Executor – запускатка: она и выполняет код

Чтобы стенд с airflow работал, нужно

1+ scheduler и 1+ worker* – "исполнитель"

(бывает нужен ещё triggerer)

а с нами как?


(Human) user:

может запустить/посмотреть пайплайны (Webserver)

может дебажить (CLI, нужен* доступ к серверу)

может делать запросы к серверу (API, есть api cli)

Executor: выделяет ресурсы и работает с ними



scheduler — узкое место


его постоянно
допиливают

до 2.0 было
очень плохо

сейчас
лучше

сильно
лучше стало в 2.7


"небольшой"
setup



```
graph RL
    A([User]) -- browser --> B1
    A([User]) -. cli? .-> Node
    subgraph Node
        B1{Web Server}
        B2((Scheduler))
        B3(Executor)
    end
    B1 --> C
    B2 <--> C
    B3 --> C[(Metadata Database)]
```

тут можно начать
упираться в базу

"большой"
setup



```
graph RL
    user([User]) --> webserver
    subgraph Master
        webserver{Web Server}
        executor(Executor)
    end
    end
    subgraph Worker Nodes
        worker1(worker 1)
        worker2(worker 2)
        worker3(worker 3)
    end
    end
    queue((Queuing Subsystem))
    webserver --> metaDB
    executor --> metaDB
    worker1 --> metaDB
    worker2 --> metaDB
    worker3 --> metaDB
    metaDB[(Metadata Database)]
    queue --> worker1
    queue --> worker2
    queue --> worker3
    executor --> queue
```



База метаданных Airflow

потенциально узкое место

PostgreSQL наше всё

MSSQL / MySQL / MariaDB / Oracle — экзотика

ничего серьёзно не работает с sqlite 🙄


LocalExecutor + PostgreSQL = $\sim 100^*$ DAGs изи

* — не является инвестиционной рекомендацией


экзе-
кю-
торы

5


LocalExecutor — "внутри" Scheduler



CeleryExecutor — управляет кластером




KubernetesExecutor — чуть сложнее



Есть и другие экзекьюторы

Executor	Scalability	Isolation	Complexity	Resource Efficiency
Sequential	Low	Low	Low	Low
Local	Mid	Low	Low	Mid
CeleryExecutor	High	Mid	Mid	Mid
KubernetesExecutor	High	High	High	High
CeleryKubernetesExecutor	High	High	High	High

Как выбрать экзекьютор?





Airflow: local setup

локально ($\approx$ для тестов) поднимается одной командой
с `sqlite+SequentialExecutor`

можно и в докере с `LocalExecutor` и постгрес
(можно и с *`CeleryExecutor/k8Executor`*, в принципе)

нужен свеженький питон (3.10+, но не самый свежак)

если локально винда то WSL2 и докер

н у и
с т о ?

Airflow отлично себя чувствует!

Airflow прекрасно себя чувствует, полон сил и фич. Ему всё ещё всё равно, что вы в нём запускаете

Если вы что-то уже делали с ним, но давно
-> Попробуйте снова с ним что-то сделать

Если вы ещё ничего не делали с Airflow
-> самое время попробовать

(Если вам не нужен оркестратор, юзайте APScheduler)



Recent фишки

Assets/Datasets:

пришли на смену Op-триггеров

Deferrable Ops:

оптимизация работы щедулера

Сахар для разработчика

декораторы для tasks вместо операторов


dynamic task mappings

TaskGroups, pools, слоты, weight rules, etc



Завершающий слайд

@shrimpsizemoose



код и ещё ссылки

<https://mosyag.in/piterpy2025>